

Detektorok jelének kiértékelése mesterséges intelligencia segítségével

Bevezetés

A fizikai kísérletek során használt detektorok jelkiértékelése gyakran időigényes manuális folyamatokat igényel, különösen nagy adatmennyiségek esetén. A hagyományos módszerek korlátai mellett azonban a mesterséges intelligencia (AI) alapú automatizálás új lehetőségeket nyit a valós idejű adatfeldolgozás területén. Bár az AI-t már széles körben alkalmazzák spektrális elemzésre [1], a jelen munka újdonsága abban rejlik, hogy egyszerű, alacsony költségű LED-szenzorok és egy mikrokontroller-alapú rendszer segítségével valósítja meg a gyors és pontos osztályozást. A kidolgozott módszer hat különböző színű LED-et használ detektorként, amelyek fotovoltaiikus üzemmódban képesek a beeső fény spektrális jellemzőit feszültségjelekké alakítani. Az ESP32 mikrokontroller ezeket az adatokat gyűjti, majd egy gépi tanulási modell elemzi és osztályozza őket – például a fény színének vagy intenzitásának meghatározására. A rendszer kifejezetten oktatási célokat szolgál, lehetővé téve a diákok számára, hogy közvetlenül megismerjék a modern adatfeldolgozás és az AI-alapú döntéshozatal gyakorlati alkalmazását. A megközelítés előnye nem csupán a költséghatékonyság és az egyszerű megvalósíthatóság, hanem az is, hogy a felhasználók saját méréseiken keresztül tanulmányozhatják a fizikai jelenségeket és az AI általuk generált adatokon való működését. A jelen cikk bemutatja a hardver és a szoftver felépítését, valamint az AI-modell tanításának, alkalmazásának és kiértékelésének módszertanát.

1. A detektor működésének fizikai alapjai

A LED-ek nemcsak fényforrásként, hanem fényérzékelőként is működhetnek. Normál üzemmódban elektrolumineszcens fénykibocsátásra képesek, de fordított polarításban – külső fény hatására – fotofeszültséget generálnak a belső fotoeffektus révén. Ennek során azok a fotonok, amelyek energiája elegendő:

$$E = h \cdot f \geq E_g$$

elektron–lyuk párokat hoznak létre a félvezetőben, amelyeket a p–n átmenet elektromos tere szétválaszt.

A LED-diódák fotodetektorként való használata azonban több fizikai hatás figyelembevételét igényli. Vegyük példaként egy piros LED-et, amelynek fénykibocsátó rétege jellemzően GaAsP vagy AlInGaP anyagból készül. A kibocsátott fény hullámhossza 620–650 nm, ami a tiltott sáv (bandgap) szélességéből következően kb. 1,8–2,0 eV energiatartománynak felel meg. A belső fotoeffektus hatására csak azok a fotonok képesek töltéshordozókat kelteni, amelyek energiája meghaladja a félvezető tiltott sáv szélességét. Ezért a pirosnál hosszabb hullámhosszú (alacsonyabb energiájú) fotonok nem hoznak létre elektron–lyuk párokat, így fotoáram sem keletkezik, ha ilyen fény világítja meg a LED-et.

Ugyanakkor a piros LED geometriai kialakítása elsősorban fénykibocsátásra optimalizált. A szerkezetében található vastag aktív réteg képes elnyelni a nagyobb energiájú (pl. 350 nm-es UV) fotonokat is, ám ezek detektálása korlátozott, mivel:

- a p–n átmenet mélyen helyezkedik el az eszköz belsejében;
- az UV-fotonok által keltett elektron–lyuk párok jelentős része rekombinálódik a felületen, mielőtt mérhető jel keletkezne.

Ez alapján az várható, hogy:

- a piros LED érzéketlen lesz a pirosnál hosszabb hullámhosszú (pl. infravörös) fényre;
- az UV-tartományban is 0 V körüli választ ad, mivel a felépítése nem teszi lehetővé a hatékony detektálást.

A legnagyobb érzékenység a saját tiltott sáv szélességéhez közeli fotonenergiák esetén várható. A spektrum narancs–zöld tartományában az érzékenység fokozatosan csökken.

Elektromos viselkedés – kimeneti feszültség

A detektorként használt LED lezárása egy 5,6 M Ω -os ellenállással azt eredményezi, hogy a fény hatására keletkező kis mértékű fotoáram hatására feszültség jelenik meg a LED kivezetésein. Ez a feszültség:

- arányos a megvilágító fény intenzitásával, azaz a keletkező töltéshordozók számával;
- de nem haladhatja meg a félvezető anyag E_g tiltott sáv szélességéhez tartozó feszültséget, azaz kb. 1,8–2,0 V-ot.

A mérési eredmények ezt a várakozást igazolják, amint az alábbi táblázat is mutatja.

Kísérleti eredmények – mért feszültségek különböző színű LED-fényekre

Szín	Hullámhossz (nm)	Fotonenergia (eV)	Mért feszültség (V)
Piros (R)	~620–650	~1,9–2,0	1,46
Narancs (O)	~590–620	~2,0–2,1	0,55
Zöld (G)	~495–570	~2,1–2,5	1,03
Kék (B)	~450–495	~2,5–2,75	1,41
UV	~350–400	~3,1–3,5	0,01 (zajszint)

Összegzés


A piros LED fotodetektorként nemcsak a saját színére, hanem a rövidebb hullámhosszú, nagyobb energiájú fényekre is érzékeny lehet. Az UV-fényre adott válasza azonban már minimális, mivel a struktúrája nem teszi lehetővé a hatékony detektálást ebben a tartományban.

A detektált feszültség felső határát a félvezető tiltott sáv szélessége korlátozza.

A leírt jelenségek nemcsak a piros LED-re, hanem más színű LED-ekre is igaznak bizonyultak. Ez is indokolja azt a megközelítést, hogy a detektorjelek kiértékeléséhez célszerű mesterséges intelligenciát (MI) alkalmazni, különösen akkor, ha azt szeretnénk eldönteni, hogy milyen színű fényforrással történt a megvilágítás [2–4].

2. A minimális hardverfelépítés

A rendszer magját egy ESP32-alapú mikrokontroller alkotja (~1500 Ft), amely integrált Wi-Fi/Bluetooth kommunikációval és elegendő számú analóg bemenettel rendelkezik. Ez lehetővé teszi a szenzoradatok valós idejű rögzítését és vezetékes/vezeték nélküli továbbítását.



1. ábra: A mérőeszköz kapcsolási rajza.

A detektoregység hat spektrálisan optimalizált, 5 mm átmérőjű LED-ből áll (365 nm, 460 nm, 520 nm, 588 nm, 601 nm, 620 nm), amelyek átlátszó házban, kör alakban vannak elhelyezve a fény egyenletes eloszlásához.



2. ábra: A detektor geometriája.

Minden LED anódja egy 5,6 M Ω -os munkaellenálláson keresztül csatlakozik az ESP32 ADC-bemeneteihez. Az elrendezés fotovoltaikus üzemmódban működik, ahol:

- a LED-ek fényérzékeny félvezetőként viselkednek;
- a generált fotoáram a munkaellenálláson feszültséggé alakul;
- az ESP32 digitálisan mintavételezi és továbbítja az adatokat.

Kritikus tervezési szempontok

- Passzív működés – külső tápellátás nem szükséges.

- Közvetlen ADC-csatlakozás – nincs jelkondicionáló áramkör.
- Kompakt elrendezés – az átlátszó ház biztosítja az optikai csatolást.

A hardver kialakítása lehetővé teszi a későbbi fejlesztéseket, például külső fényzáró burkolat vagy szűrők hozzáadását pontosabb spektrális mérésekhez.

3. Az ESP32-n futó szoftver

Az ESP32 mikrokontroller Arduino IDE-ben fejlesztett firmware-e 200 ms időközönként mintavételezi a hat LED-szenzor analóg jeleit, és a nyers feszültségértékeket CSV-formátumban továbbítja USB-n vagy Bluetooth-on keresztül. A szoftver szándékosan nem végez adatfeldolgozást – ez lehetővé teszi, hogy a gépi tanulási modell különböző eszközökön fusson, miközben a hardver változatlan marad.

A rendszer modularitását hangsúlyozza, hogy a firmware nyílt forráskódú, így testre szabható az oktatási vagy kutatási igényekhez. A kód tartalmaz konfigurációs lehetőségeket a kommunikációs protokollok paramétereinek módosítására, valamint diagnosztikai üzenetek küldésére hibakeresés céljából.

4. Az AI-modell szerepe a kiértékelésben

A rendszer a hat LED-szenzor nyers feszültségadatait gépi tanulási modell segítségével dolgozza fel. A modell a különböző színű fényforrásokra jellemző feszültségmintázatokat tanulja meg, lehetővé téve a mért fény színének (piros, zöld, kék stb.) vagy hiányának (sötét) automatikus azonosítását.

A betanítás során címkézett adatokat használunk: a LED-ek válaszait párosítjuk az ismert fényforrások színével. A betanított modell ezt követően valós időben képes osztályozni az új méréseket, és a döntéshez valószínűségi értékeket is rendel. Ez különösen hasznos a kevésbé egyértelmű vagy egymáshoz hasonló detektorválaszok esetén.

A rendszer a többosztályos osztályozási feladathoz a Microsoft ML.NET keretrendszerét használja. A bemutatott mintaalkalmazásban a modell betanítása az **LbfgsMaximumEntropy** algoritmussal történik. A modell a hat LED-detektor által szolgáltatott feszültségértékek alapján tanulja meg az egyes megvilágítási kategóriákhoz tartozó jellegzetes mintázatokat.

A feldolgozás C# környezetben valósul meg. A betanított modell valós időben értékeli az ESP32-től érkező mérési adatokat, meghatározza a legvalószínűbb kategóriát, és megjeleníti a döntéshez tartozó valószínűségi értékeket is.

A modell teljesítményének objektív vizsgálatához az alkalmazás a rendelkezésre álló címkézett adatokat **80/20 arányban tanító- és tesztalmazra osztja**. A modell betanítása az adatok 80%-án történik, míg a fennmaradó 20% a modell által a tanítás során nem látott adatokon végzett kiértékelést szolgálja.

A kiértékelés során az alkalmazás megjeleníti a **Micro Accuracy**, **Macro Accuracy** és **Log Loss** mérőszámokat, valamint egy színezett **konfúziós mátrixot**. A Micro Accuracy az összes helyes besorolás arányát jellemzi, míg a Macro Accuracy az egyes kategóriák eredményeit azonos súllyal veszi figyelembe. A Log Loss a modell valószínűségi előrejelzéseinek minőségéről ad információt; kisebb értéke jobb eredményt jelent.

A konfúziós mátrix soraiban a tényleges kategóriák, oszlopaiban a modell által előre jelzett kategóriák szerepelnek. A főátló elemei a helyes besorolásokat, a főátlón kívüli értékek pedig a téves osztályozásokat mutatják. A mátrix így nemcsak azt teszi láthatóvá, hogy összességében milyen jól teljesít a modell, hanem azt is, hogy **mely kategóriákat hajlamos egymással összetéveszteni**.


A teszteléshez készített mintaalkalmazás nyílt forráskódú, így a modell tanításának, valós idejű alkalmazásának és kiértékelésének teljes folyamata tanulmányozható és oktatási célokra felhasználható.

5. A C#-ban írt mintaalkalmazás bemutatása

A kiértékelő rendszer egy Windows operációs rendszeren futó, C# nyelven fejlesztett asztali mintaalkalmazás, amely az ESP32 mikrokontrollertől érkező adatokat dolgozza fel és jeleníti meg. Az alkalmazás a következő fő funkciókat valósítja meg:


- ✓ **Valós idejű adatfogadás soros porton keresztül:** minden beérkező adatsor a hat LED-detektor mért feszültségértékeit tartalmazza.
- ✓ **Adatok rögzítése és címkézése:** a felhasználó kiválaszthatja az adott minta színét (pl. Red, Green, UV stb.), majd az adatokat CSV-fájlba mentheti tanítás céljára.
- ✓ **AI-modell betanítása:** a beépített gépi tanulási pipeline a Microsoft ML.NET keretrendszerét használja. A betanítás történhet frissen gyűjtött vagy korábban fájlba mentett adatokkal. A modell többsztályos osztályozó algoritmusként az **LbfgsMaximumEntropy** eljárást alkalmazza.
- ✓ **A modell teljesítményének kiértékelése:** a program a címkézett adatokat 80/20 arányban tanító- és tesztalmazra osztja. A tesztalmazon Micro Accuracy, Macro Accuracy és Log Loss értékeket számít, a kategóriánkénti osztályozási eredményeket pedig színezett konfúziós mátrixban jeleníti meg.
- ✓ **Valós idejű osztályozás:** betanítás után az újonnan beérkező szenzoradatokat a program automatikusan osztályozza, majd megjeleníti a legvalószínűbb kategóriát.
- ✓ **Predikciós valószínűségek megjelenítése:** a program nemcsak a legvalószínűbb szint mutatja, hanem a három legvalószínűbb kategória nevét és százalékos valószínűségét is.
- ✓ **Interaktív vizualizáció:** a szenzoradatok táblázatban jelennek meg, a tanítóadatok statisztikája pedig folyamatosan frissül.

Az alkalmazás kezelőfelületének ablaka a 3. ábrán látható.



3. ábra: A C#-ban írt mintaalkalmazás vezérlőfelülete.

A modell betanítása után külön kiértékelő ablakban vizsgálhatók a tesztalmazon kapott eredmények. A számszerű teljesítménymutatók mellett megjelenő konfúziós mátrix segítségével közvetlenül azonosíthatók a helyesen felismert, illetve az egymással összetévesztett kategóriák.



4. ábra: A betanított modell kiértékelése. A program a Micro Accuracy, Macro Accuracy és Log Loss mérőszámok mellett színezett konfúziós mátrixban mutatja az egyes kategóriák helyes és téves besorolásait.

Az alkalmazás célja nemcsak a technikai működés biztosítása, hanem az is, hogy tanórai környezetben a tanulók saját maguk is összegyűjthessék és címkézhessek a tanítóadatokat, betaníthassák a modellt, majd objektív mérőszámok segítségével értékelhessék annak teljesítményét. Így közvetlen tapasztalatot szerezhetnek a gépi tanulás teljes folyamatáról az adatgyűjtéstől a modell kiértékeléséig.

A teljes forráskód és a program telepítője szabadon elérhető és felhasználható.

6. Tanórai alkalmazás és oktatási lehetőségek

A bemutatott detektorrendszer és a hozzá kapcsolódó szoftveres környezet kiválóan alkalmazható középiskolai fizika- vagy Science-órákon, különösen olyan témák feldolgozására, mint a fény és anyag kölcsönhatása, a fotoeffektus, a szenzortechnika, valamint a mesterséges intelligencia alapfogalmai.

6.1. Tantárgyi kapcsolódások

- **Fizika:** belső fotoeffektus, félvezetők működése, fény hullámhossza, elektromos feszültség mérése.

- **Digitális kultúra/Informatika:** adatgyűjtés, adatfeldolgozás, programozás, MI-modellek működése és kiértékelése.
- **Kutató projekteken alapuló tanulás:** a tanulók saját mintavételt végezhetnek, betaníthatják a modellt, majd megvizsgálhatják annak teljesítményét.

6.2. Tanulói tevékenységek

A rendszer használata során a tanulók aktívan bekapcsolódhatnak a kísérletbe:

- A szenzor segítségével különböző fényforrásokat vizsgálnak (pl. LED, telefon vaku, napfény, UV-lámpa).
- Méréseket végeznek és adatokat gyűjtenek egy-egy színosztályhoz.
- Az adatokat elmentik és címkézik.
- A rendelkezésre álló adatok felhasználásával betanítták a gépi tanulási modellt.
- A modell teljesítményét a teszhalmazon számított mérőszámok és a konfúziós mátrix segítségével értékelik.
- Valós időben tesztelik az osztályozó működését, és értelmezik a predikciós valószínűségeket.
- Megvizsgálják, mikor téved a modell, és a konfúziós mátrix alapján azonosítják, hogy mely kategóriákat keveri össze egymással.
- Megbeszéljük, hogyan befolyásolja az adatgyűjtés minősége és a tanítóadatok összetétele a modell megbízhatóságát.

Ez a megközelítés lehetőséget ad arra, hogy a tanulók kísérletező módon ismerkedjenek meg a mesterséges intelligencia alapjaival, megtapasztalják a szenzoradatok fizikai jelentését, valamint megtanulják, hogyan kell adatokat gyűjteni, elemezni, feldolgozni és egy gépi tanulási modell teljesítményét értékelni.

6.3. Didaktikai előnyök

- **Projektalapú tanulás:** a diákok valódi problémát oldanak meg, amelyhez saját adatokat gyűjthetnek, majd az általuk létrehozott adathalmazzal taníthatják és értékelhetik a modellt.
- **Interdiszciplinaritás:** a rendszer természetes módon kapcsolja össze a természettudományos és informatikai tartalmakat.
- **A gépi tanulás folyamatának megértése:** a tanulók nem csupán egy kész AI-rendszer eredményét látják, hanem végigkövethetik az adatgyűjtés, címkézés, tanítás, tesztelés és kiértékelés teljes folyamatát.

- **A modell hibáinak értelmezése:** a konfúziós mátrix segítségével láthatóvá válik, hogy a mesterséges intelligencia nem „tévedhetetlen fekete doboz”; a tanulók konkrétan megvizsgálhatják, mely esetekben és milyen kategóriák között követ el hibákat.
- **Motiváció és önállóság:** a tanulók látható, kézzel fogható eredményt hoznak létre – egy saját adatokkal betanított és mérhető teljesítményű AI-rendszert.

Hivatkozások

- [1] *Machine Learning Techniques for Optical Spectrum Analysis*. IEEE Photonics Journal.
- [2] E. Vannacci, S. Granchi, M. Calzolari, E. Biagi: *Applications of light emitting diodes as sensors of their own emitted light*. Department of Information Engineering (DINFO), University of Florence, Via Santa Marta 3, 50139 Florence.
- [3] Homemade-physics.de: *bandluecke-photonenenergie*.
- [4] Schirripa Spagnolo, G., Leccese, F., Leccisi, M. (2019): *LED as transmitter and receiver of light: A simple tool to demonstration photoelectric effect*. Crystals, 9(10), 531. DOI: 10.3390/cryst9100531.